Preparación y Análisis de datos

Capítulo 1: Manipulación avanzada de datos

Mg. J. Eduardo Gamboa U.

2025-03-24

Presentación

Docente: Mg. Jesús Eduardo Gamboa Unsihuay

Correo: jgamboa@lamolina.edu.pe

Repositorio:

Descripción

Este curso está diseñado para personas con conocimientos básicos en R que desean profundizar en la manipulación de datos, el análisis inferencial y la generación de reportes automatizados. A través de un enfoque práctico, los participantes aprenderán a preprocesar datos de manera eficiente, aplicar técnicas estadísticas para la toma de decisiones y comunicar sus hallazgos de manera efectiva mediante reportes reproducibles en RMarkdown

Contenido

1. Manipulación avanzada de datos:
   - Manejo de datos con el paquete dplyr
   - Transformación de estructuras de datos con el paquete tidyr
   - Manejo de fechas con el paquete lubridate
   - Manipulación de datos textuales con el paquete stringr
2. Análisis inferencial de datos:
   - Intervalos de confianza con R
   - Pruebas de hipótesis con R
   - Regresión lineal con R
3. Generación de reportes con RMarkdown

Manejo de datos con el paquete dplyr

`dplyr` es un paquete de R diseñado por Hadley Wickham (RStudio) para la manipulación eficiente de datos. Es parte del ecosistema `tidyverse`.

Proporciona una "gramática" (particularmente verbos) para la manipulación y operaciones con data frames.

Principales funciones de dplyr:

- `select()`: Selecciona columnas específicas.
- `filter()`: Filtra filas según condiciones.
- `mutate()`: Crea o modifica columnas.
- `arrange()`: Ordena filas según valores de una o más columnas.
- `group_by()`: Agrupa los datos por categorías.
- `left_join()`, `inner_join()`, `right_join()`, `full_join()` : Une tablas de datos.

Operador pipe

Operador pipe nativo: `|>`

- Disponible desde la versión 4.1.0 de R
- No requiere cargar ningún paquete
- Siempre es obligatorio el uso de paréntesis

Operador pipe de `magrittr`: `%>%`

- Disponible con el paquete `magrittr` (o `dplyr` o `tidyverse`)
- Cuando la función solo tiene un argumento, es opcional el uso de paréntesis

Ejemplo

```
x = c(1,5,6,3,-2)
sum(x)
```

```
[1] 13
```

```
x |> sum()
```

```
[1] 13
```

```
library(dplyr)
x %>% sum
```

```
[1] 13
```

Función select()

```
df |> select(posiciones o nombres de las variables a ser seleccionadas)

df |> select(-posiciones o nombres de las variables a ser eliminadas)
```

Ejemplo

Leer el archivo INEI.csv.

```
df = read.csv2('INEI.csv')
```

Seleccionar las columnas Departamento, Provincia y Cantidad.

```
df |> select('Departamento','Provincia','Cantidad')
df |> select(3, 4, 8)
```

Seleccionar todas las columnas excepto ubigeo_reniec y ubigeo_inei

```
df |> select(-'ubigeo_reniec',-'ubigeo_inei')
df |> select(-1, -2)
```

Función `pull()`

```
df |> pull(posición o nombre de la variable a ser seleccionada)
```

Ejemplo

Seleccionar la columna `Distrito` como un vector

```
df |> pull(Distrito)
df |> pull(4)
```

Función `filter()`

```
df |> filter(reglas de filtro)
```

Ejemplo

Filtrar los registros correspondientes al sexo masculino

```
df |> filter(Sexo == "M")
```

Filtrar los registros correspondientes a cantidades inferiores a 100 habitantes

```
df |> filter(Cantidad < 100)
```

Filtrar los registros correspondientes al sexo masculino **y** a cantidades inferiores a 100 habitantes

```
df |> filter((Sexo == "M") & (Cantidad < 100))
```

Filtrar los registros correspondientes al sexo masculino **o** a cantidades inferiores a 100 habitantes

```
df |> filter((Sexo == "M") | (Cantidad < 100))
```

Función `mutate()`

```
df |> mutate(nueva_variable = regla para crear la nueva variable)
df |> mutate(variable_existente = regla para modificar la variable)
```

Ejemplo

Convertir el sexo a minúscula, almacenándolo en la misma variable.

```
df |> mutate(Sexo = tolower(Sexo))
```

Crear una variable que se llame `Alta_Cantidad` si la cantidad de habitantes es mayor a 300.

```
df |> mutate(Alta_Cantidad = ifelse(Cantidad>300,"Sí","No"))
```

Crear una variable binaria (0=No, 1=Sí) para distinguir al grupo vulnerable de adultos mayores (60 a más años)

```
Edades_am = c("60-64", "65-69", "70-74", "75-79", "80+")
df |> mutate(Es_AdultoMayor = ifelse(Edad_Anio %in% Edades_am, 1, 0))
```

¿Cómo hacer los 3 cambios anteriores en simultáneo?

```
Edades_am = c("60-64", "65-69", "70-74", "75-79", "80+")
df |> mutate(Sexo           = tolower(Sexo),
             Alta_Cantidad  = ifelse(Cantidad>300,"Sí","No"),
             Es_AdultoMayor = ifelse(Edad_Anio %in% Edades_am, 1, 0))
```

De otra manera:

```
Edades_am = c("60-64", "65-69", "70-74", "75-79", "80+")
df |>
  mutate(Sexo           = tolower(Sexo)) |>
  mutate(Alta_Cantidad  = ifelse(Cantidad>300,"Sí","No")) |>
  mutate(Es_AdultoMayor = ifelse(Edad_Anio %in% Edades_am, 1, 0))
```

Función arrange()

```
df |> arrange(variable) # orden alfabético A - Z, o de menor a mayor
df |> arrange(desc(variable)) # orden alfabético Z - A, o de mayor a menor
df |> arrange(-variable numérica) # orden de mayor a menor
```

Ejemplo

Ordenar el data frame según la cantidad de habitantes, de menor a mayor

```
df |> arrange(Cantidad)
```

Ordenar el data frame según la cantidad de habitantes, de mayor a menor

```
df |> arrange(-Cantidad)
df |> arrange(desc(Cantidad))
```

Ordenar alfabéticamente según departamento, de la A a la Z

```
df |> arrange(Departamento)
```

Ordenar alfabéticamente según departamento, de la Z a la A

```
df |> arrange(desc(Departamento))
```

Ordenar alfabéticamente según departamento (de la A a la Z) y luego según provincia (de la A a la Z)

```
df |> arrange(Departamento,Provincia)
```

Ordenar alfabéticamente según departamento (de la A a la Z) y luego según provincia (de la Z a la A)

```
df |> arrange(Departamento,desc(Provincia))
```

Funciones de integración de datos

En ocasiones, nuestros datos no están presentes en un único data frame y necesitamos juntar dos o más de estos.

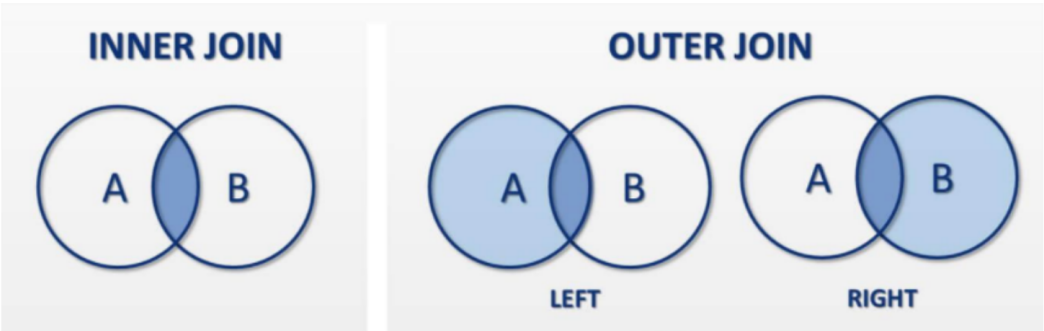

- `inner_join(x, y)`: Retorna las filas de x que tienen valores coincidentes en y, manteniendo todas las columnas de ambas tablas. Solo conserva las coincidencias.
- `left_join(x, y)`: Retorna todas las filas de x y agrega las columnas de y cuando hay coincidencias. Si no existen coincidencias, se completan con NA.
- `right_join(x, y)`: Retorna todas las filas de y y agrega las columnas de x cuando hay coincidencias. Si no existen coincidencias, se completan con NA.
- `full_join(x, y)`: Retorna todas las filas de x y y, combinando sus columnas. Cuando no hay coincidencias en alguna de las tablas, los valores faltantes se completan con NA.

Ejemplo

Data frame de empleados

```
empleados <- data.frame(
  ID = c(1, 2, 3, 4),
  Nombre = c("Luisa", "Bruno", "Ana", "Renato"),
  Departamento = c("Ventas", "TI", "RRHH", "Marketing")
)
```

Data frame de salarios

```
salarios <- data.frame(
  ID = c(2, 3, 5),
  Salario = c(5000, 6000, 4500)
)
```

```
empleados
```

```
  ID Nombre Departamento
1  1  Luisa       Ventas
2  2  Bruno           TI
3  3    Ana         RRHH
4  4 Renato    Marketing
```

```
salarios
```

```
  ID Salario
1  2    5000
2  3    6000
3  5    4500
```

```r
empleados |> inner_join(salarios, by = "ID")
```

```
  ID Nombre Departamento Salario
1  2  Bruno           TI    5000
2  3    Ana         RRHH    6000
```

```r
empleados |> left_join(salarios, by = "ID")
```

```
  ID Nombre Departamento Salario
1  1  Luisa       Ventas      NA
2  2  Bruno           TI    5000
3  3    Ana         RRHH    6000
4  4 Renato    Marketing      NA
```

```r
empleados |> right_join(salarios, by = "ID")
```

```
  ID Nombre Departamento Salario
1  2  Bruno           TI    5000
2  3    Ana         RRHH    6000
3  5   <NA>         <NA>    4500
```

```r
empleados |> full_join(salarios, by = "ID")
```

```
  ID Nombre Departamento Salario
1  1  Luisa       Ventas      NA
2  2  Bruno           TI    5000
3  3    Ana         RRHH    6000
4  4 Renato    Marketing      NA
5  5   <NA>         <NA>    4500
```

Transformación de estructuras de datos con tidyr

`tidyr` es un paquete de R diseñado por Hadley Wickham (RStudio) para limpiar y transformar datos en un formato ordenado. Es parte del ecosistema `tidyverse`. Su utilidad en el preprocesamiento es diversa, para tareas como:

- Transformación entre formatos ancho y largo
- Separación y unión de columnas de texto
- Manejo de valores faltantes

Transformación de formato ancho a largo

Función `pivot_longer`

```
df |>
  pivot_longer(
    cols = columnas_a_convertir,  # Columnas que pasarán a formato largo
    names_to = "nombre_nueva_columna",  # Columna con nombres originales
    values_to = "nombre_valores"  # Columna que contendrá los datos
  )
```

Ejemplo

Supongamos que tenemos este data frame de un diseño experimental

```
x1 = c(15,14,18,17)
x2 = c(20,19,15,17)
x3 = c(12,13,11,16)
datos = data.frame(trat1 = x1, trat2 = x2, trat3 = x3)
datos
```

```
  trat1 trat2 trat3
1    15    20    12
2    14    19    13
3    18    15    11
4    17    17    16
```

```r
library(tidyr)
datos |> pivot_longer(cols = c("trat1","trat2","trat3"),
                      names_to = "Tratamiento",
                      values_to = "Rendimiento")
```

```
# A tibble: 12 x 2
   Tratamiento Rendimiento
   <chr>              <dbl>
 1 trat1                 15
 2 trat2                 20
 3 trat3                 12
 4 trat1                 14
 5 trat2                 19
 6 trat3                 13
 7 trat1                 18
 8 trat2                 15
 9 trat3                 11
10 trat1                 17
11 trat2                 17
12 trat3                 16
```

Transformación de formato largo a ancho

Función `pivot_wider`

```
df |>
  pivot_wider(
    names_from = nombre_columna_a_convertir,
    # Columna que originará columnas

    values_from = nombre_columna_valores
    # Columna con los valores que se distribuirán en las columnas
  )
```

Ejemplo

Supongamos que tenemos este data frame:

```
x1 = c("Ingreso","Egreso","Ingreso","Egreso","Ingreso","Egreso")
x2 = c("Lunes","Lunes","Martes","Martes","Miércoles","Miércoles")
x3 = c(20,16,25,12,30,18)
datos = data.frame(tipo = x1, dia = x2, cantidad = x3)
datos
```

```
     tipo       dia cantidad
1 Ingreso     Lunes       20
2  Egreso     Lunes       16
3 Ingreso    Martes       25
4  Egreso    Martes       12
5 Ingreso Miércoles       30
6  Egreso Miércoles       18
```

```r
datos |> pivot_wider(names_from = dia,
                     values_from = cantidad)
```

```
# A tibble: 2 x 4
  tipo    Lunes Martes Miércoles
  <chr>   <dbl>  <dbl>     <dbl>
1 Ingreso    20     25        30
2 Egreso     16     12        18
```

Separación de columnas de texto

Función `separate`

```
df |>
  separate(col = columna_a_expandir, # columna que se expandirá
           into = nuevos_nombres, # nuevas columnas que se crearán
           sep = separador) # caracter que servirá para separar
```

Ejemplo

```
df <- data.frame(NombreCompleto = c("Ana Juárez Ramírez",
                                    "Raúl Gómez Vargas",
                                    "Beatriz Castillo Castillo"))
```

```
df
```

```
             NombreCompleto
1         Ana Juárez Ramírez
2          Raúl Gómez Vargas
3 Beatriz Castillo Castillo
```

```
df |>
  separate(NombreCompleto, into = c("Nombre", "Apellido"), sep = " ")
```

```
   Nombre Apellido
1     Ana   Juárez
2    Raúl    Gómez
3 Beatriz Castillo
```

Unión de columnas de texto

Función `unite`

```
df |>
  unite(col = nueva_columna,  # Nombre de la nueva columna combinada
        columnas_a_unir,  # Columnas que se unirán
        sep = separador)  # Caracter que se usará para unir los valores
```

Ejemplo

```
x1 = c("EP","ZT","CC")
x2 = c("03","02","01")
x3 = c("01","02","01")
x4 = c(3,4,2,3,3,4)
df = data.frame(codfac = x1, nivel = x2, numero = x3, creditos = 4)
```

```
df
```

```
  codfac nivel numero creditos
1     EP    03     01        4
2     ZT    02     02        4
3     CC    01     01        4
```

```
df |> unite(col = cod_curso,
            codfac, nivel, numero,
            sep = "")
```

```
  cod_curso creditos
1    EP0301        4
2    ZT0202        4
3    CC0101        4
```

Eliminación de valores faltantes

Función `drop_na`

```
df |> drop_na()
```

Ejemplo

```
x1 = c("María","Ana","Fernando","Eduardo")
x2 = c(2,1,NA,4)
x3 = c("Ate","Lince","Bellavista",NA)
df = data.frame(Persona = x1, Mascotas = x2, Distrito = x3)
```

```
df
```

```
   Persona Mascotas   Distrito
1    María        2        Ate
2      Ana        1      Lince
3 Fernando       NA Bellavista
4  Eduardo        4       <NA>
```

```
df |> drop_na()
```

```
  Persona Mascotas Distrito
1   María        2      Ate
2     Ana        1    Lince
```

Susbtitución de valores faltantes

Función `replace_na`

```
df |> replace_na(list(variable1 = valor_a_sustituir,
                      variable2 = valor_a_sustituir))
```

Ejemplo

```
x1 = c("María","Ana","Fernando","Eduardo")
x2 = c(2,1,NA,4)
x3 = c("Ate","Lince","Bellavista",NA)
df = data.frame(Persona = x1, Mascotas = x2, Distrito = x3)
```

```
df
```

```
   Persona Mascotas   Distrito
1    María        2        Ate
2      Ana        1      Lince
3 Fernando       NA Bellavista
4  Eduardo        4       <NA>
```

```
df |> replace_na(list(Mascotas =  0, Distrito = "Sin datos"))
```

```
   Persona Mascotas   Distrito
1    María        2        Ate
2      Ana        1      Lince
3 Fernando        0 Bellavista
4  Eduardo        4  Sin datos
```

Manejo de fechas con el paquete lubridate

El paquete `lubridate` facilita el trabajo con fechas en R, simplificando su creación, conversión, manipulación y extracción de componentes.

Creación de fechas a partir de strings

Las funciones `ymd()`, `dmy()`, `mdy()`, etc., convierten texto en fechas reales

```
library(lubridate)

fecha1_str  = "2025-03-26"
fecha1_str |> str()
```

```
 chr "2025-03-26"
```

```
fecha1_date = fecha1_str |> ymd()
fecha1_date |> str()
```

```
 Date[1:1], format: "2025-03-26"
```

```
fecha2_str  = "07/Apr/2025"
fecha2_str |> str()
```

```
 chr "07/Apr/2025"
```

```
fecha2_date = fecha2_str |> dmy()
fecha2_date |> str()
```

```
 Date[1:1], format: "2025-04-07"
```

```
fecha3_str = "2025-03-18 14:30:45"
fecha3_str |> str()
```

```
 chr "2025-03-18 14:30:45"
```

```
fecha3_date = fecha3_str |> ymd_hms()
fecha3_date |> str()
```

```
 POSIXct[1:1], format: "2025-03-18 14:30:45"
```

Recordemos el uso de la función `mutate`:

Considere el siguiente data frame:

```
x1 = c("Mauricio","Katy","Pablo","Ana")
x2 = c(19980512,20051230,20070707,20010919)
df = data.frame(Nombre = x1, FechaNac = x2)
df
```

```
    Nombre FechaNac
1 Mauricio 19980512
2     Katy 20051230
3    Pablo 20070707
4      Ana 20010919
```

Convertir la columna `FechaNac` a formato fecha.

Extracción de componentes de una fecha

```
fecha = ymd("2025-03-01")
fecha |> year()
```

```
[1] 2025
```

```
fecha |> month()
```

```
[1] 3
```

```
fecha |> day()
```

```
[1] 1
```

```r
fecha = ymd("2025-03-01")
fecha |> yday()
```

```
[1] 60
```

```r
fecha |> wday(label = TRUE, abbr = FALSE)
```

```
[1] sábado
7 Levels: domingo < lunes < martes < miércoles < jueves < ... < sábado
```

```r
fecha |> semester()
```

```
[1] 1
```

```r
fecha |> quarter()
```

```
[1] 1
```

```r
fecha |> week()
```

```
[1] 9
```

```r
fecha = ymd("2025-03-01")
fecha |> year()
```

```
[1] 2025
```

```r
fecha |> year() <- 2024
fecha
```

```
[1] "2024-03-01"
```

```
fecha_hora = ymd_hms("2025-03-18 14:30:45")
fecha_hora |> hour()
```

```
[1] 14
```

```
fecha_hora |> minute()
```

```
[1] 30
```

```
fecha_hora |> second()
```

```
[1] 45
```

Recordemos el uso de la función `mutate`:

Considere el siguiente data frame:

```
x1 = c("Mauricio","Katy","Pablo","Ana")
x2 = c(19980512,20051230,20070707,20010919)
df = data.frame(Nombre = x1, FechaNac = x2)
df
```

```
    Nombre FechaNac
1 Mauricio 19980512
2     Katy 20051230
3    Pablo 20070707
4      Ana 20010919
```

Añadir tres columnas: una para el año de nacimiento, otra para el semestre y una tercera para el día de la semana en que nacieron las personas.

Adición o sustracción de periodos de tiempo

```
fecha = ymd("2025-03-01")
fecha1 = fecha + days(5)
fecha1
```

```
[1] "2025-03-06"
```

```
fecha2 = fecha - weeks(2)
fecha2
```

```
[1] "2025-02-15"
```

```
fecha3 = fecha + years(4)
fecha3
```

```
[1] "2029-03-01"
```

```r
fecha_hora = ymd_hms("2025-03-18 14:30:45")
fecha_hora + hours(3)
```

```
[1] "2025-03-18 17:30:45 UTC"
```

```r
fecha_hora - minutes(10)
```

```
[1] "2025-03-18 14:20:45 UTC"
```

```r
fecha_hora - seconds(44)
```

```
[1] "2025-03-18 14:30:01 UTC"
```

Manipulación de datos textuales con el paquete stringr

`stringr` es un paquete de R diseñado por Hadley Wickham (RStudio) que contiene herramientas internamente coherentes para trabajar con cadenas de caracteres, es decir, secuencias de caracteres entre comillas. Facilita tareas como extracción, transformación, limpieza, búsqueda y análisis de texto, evitando la complejidad de las expresiones regulares.

Carguemos el paquete:

```
library(stringr)
```

Longitud de texto

Función `str_length`

Mide la longitud de una cadena de caracteres

```
cadena |> str_length()
```

Ejemplos

```
m = "miércoles"
m |> str_length()
```

```
[1] 9
```

```
x = c("Economía", "    Administración y   finanzas ", "Economía ",
      "Negocios", "Estadística","Física")
x |> str_length()
```

```
[1]  8 32  9  8 11  6
```

Función `str_trim`

Recorta espacios en blanco al inicio, al final o en ambos lados.

```
cadena |> str_trim(side)
```

Ejemplos

```
m = "miércoles"
m |> str_trim()
```

```
[1] "miércoles"
```

```
x = c("Economía", "    Administración y   finanzas ", "Economía ",
      "Negocios", "Estadística","Física")
x |> str_trim(side = "both")
```

```
[1] "Economía"                    "Administración y   finanzas"
[3] "Economía"                    "Negocios"
[5] "Estadística"                 "Física"
```

Función `str_squish`

Recorta espacios inclusive dentro del texto

```
cadena |> str_squish()
```

Ejemplos

```
m = "miércoles"
m |> str_squish()
```

```
[1] "miércoles"
```

```
x = c("Economía", "    Administración y   finanzas ", "Economía ",
      "Negocios", "Estadística","Física")
x |> str_squish()
```

```
[1] "Economía"                  "Administración y finanzas"
[3] "Economía"                  "Negocios"
[5] "Estadística"               "Física"
```

Modificación de cadenas

Función `str_to_lower`

Convierte el texto a minúsculas

```
cadena |> str_to_lower()
```

Ejemplos

```
m = "miércoles"
m |> str_to_lower()
```

```
[1] "miércoles"
```

```
x = c("Economía", "    Administración y   finanzas ", "Economía ",
      "Negocios", "Estadística","Física")
x |> str_to_lower()
```

```
[1] "economía"                          "    administración y   finanzas "
[3] "economía "                         "negocios"
[5] "estadística"                       "física"
```

Función `str_to_upper`

Convierte el texto a mayúsculas

```
cadena |> str_to_upper()
```

Ejemplos

```
m = "miércoles"
m |> str_to_upper()
```

```
[1] "MIÉRCOLES"
```

```
x = c("Economía", "    Administración y   finanzas ", "Economía ",
      "Negocios", "Estadística","Física")
x |> str_to_upper()
```

```
[1] "ECONOMÍA"                          "    ADMINISTRACIÓN Y   FINANZAS "
[3] "ECONOMÍA "                         "NEGOCIOS"
[5] "ESTADÍSTICA"                       "FÍSICA"
```

Función `str_to_title`

Convierte el texto a formato título (cada palabra con mayúscula inicial)

```
cadena |> str_to_title()
```

Ejemplos

```
m = "miércoles"
m |> str_to_title()
```

```
[1] "Miércoles"
```

```
x = c("Economía", "    Administración y   finanzas ", "Economía ",
      "Negocios", "Estadística","Física")
x |> str_to_title()
```

```
[1] "Economía"                          "    Administración Y   Finanzas "
[3] "Economía "                         "Negocios"
[5] "Estadística"                       "Física"
```

Función `str_replace`

Reemplaza la primera coincidencia en cada cadena de un vector

```
vector |> str_replace(patron,reemplazo)
```

```
x = c("Economía", "    Administración y   finanzas ", "Economía ",
      "Negocios", "Estadística","Física")
x |> str_replace("   finanzas", " negocios internacionales")
```

```
[1] "Economía"
[2] "    Administración y negocios internacionales "
[3] "Economía "
[4] "Negocios"
[5] "Estadística"
[6] "Física"
```

Función `str_replace_all`

Reemplaza todas las coincidencias en cada cadena de un vector

```
vector |> str_replace_all(patron,reemplazo)
```

```
x = c("Economía", "    Administración y   finanzas ", "Economía ",
      "Negocios", "Estadística","Física")
x |> str_replace_all(" ","_")
```

```
[1] "Economía"                          "____Administración_y___finanzas_"
[3] "Economía_"                         "Negocios"
[5] "Estadística"                       "Física"
```

Detección de coincidencias

Función `str_detect`

Detecta la presencia (`TRUE`) o ausencia (`FALSE`) de un patrón en un vector de caracteres.

```
cadena |> str_detect(patron)
```

Ejemplos

```
m = "miércoles"
m |> str_detect("c")
```

```
[1] TRUE
```

```
x = c("Economía", "    Administración y   finanzas ", "Economía ",
      "Negocios", "Estadística","Física")
x |> str_detect("Economía")
```

```
[1]  TRUE FALSE  TRUE FALSE FALSE FALSE
```

```
x |> str_detect("Ambiental")
```

```
[1] FALSE FALSE FALSE FALSE FALSE FALSE
```

Función `str_which`

Encuentra la posición dentro una vector de caracteres en el que se encuentra el patrón de búsqueda.

```
vector |> str_which(patron)
```

Ejemplo

```
x = c("Economía", "    Administración y   finanzas ", "Economía ",
      "Negocios", "Estadística","Física")
x |> str_which("Economía")
```

```
[1] 1 3
```

```
x |> str_which("Ambiental")
```

```
integer(0)
```

Función `str_count`

Cuenta el número de coincidencias de un patrón en cada elemento de un vector de caracteres

```
vector |> str_count(patron)
```

Ejemplos

```
m = "miércoles"
m |> str_count("e")
```

```
[1] 1
```

```
x = c("Economía", "    Administración y   finanzas ", "Economía ",
      "Negocios", "Estadística","Física")
x |> str_count("o")
```

```
[1] 2 0 2 2 0 0
```

```
x |> str_count("n")
```

```
[1] 1 4 1 0 0 0
```

Aplicación 1

1. Una tienda en línea tiene una base de datos con información de ventas y clientes. Sin embargo, los nombres de los productos presentan inconsistencias en mayúsculas/minúsculas y espacios en blanco, y se necesita extraer información clave de las fechas de venta.

a. Leer los archivos ventas.csv y clientes.xlsx, en dos data frames llamados ventas y clientes

b. Estandarizar los nombres de los productos eliminando espacios adicionales y asegurando que la primera letra de cada palabra sea mayúscula.

c. Convertir la columna `Fecha` en formato Date y extraer el año, mes y día de la semana.

d. Usar `left_join()` para unir ambas bases de datos.

e. Guardar el data frame procesado en un archivo ventas_procesadas.csv.

Aplicación 2

En un curso universitario, los docentes llevan un registro de asistencia en una tabla donde cada columna representa un día de clases. Sin embargo, la base de datos presenta nombres con espacios innecesarios y las fechas están en formato de texto. Además, se necesita calcular cuántas faltas tiene cada estudiante.

a. Leer el archivo asistencia.xlsx en un data frame llamado asistencia

b. Eliminar espacios extra y asegurar que los nombres estén correctamente capitalizados (uso correcto de mayúsculas y minúsculas).

c. Usar `pivot_longer()` para convertir la tabla, de modo que cada fila represente un estudiante en una fecha específica.

d. Transformar la columna `Fecha` en formato Date

e. Mostrar el registro de todas las inasistencias.

Aplicación 3

Una tienda recopila reseñas de clientes sobre sus productos. Para mejorar la atención al cliente, quieren identificar reseñas con comentarios negativos y contar cuántas veces se menciona la palabra "producto" en cada comentario.

a. Leer el archivo reseñas.xlsx en un data frame de nombre reseñas

b. Crear una nueva columna `Menciona_Excelente` que contenga `TRUE` si el comentario incluye la palabra "excelente".

c. Crear una nueva columna `Menciona_Mala` que contenga `TRUE` si el comentario incluye "mala", "lento" o "no volveré".

d. Crear una nueva columna `Cantidad_Producto` que cuente cuántas veces aparece la palabra "producto" en cada comentario.

e. Crear un nuevo data frame con solo los comentarios problemáticos